

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
ФАКУЛЬТЕТ КОМПЬЮТЕРНЫХ НАУК

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
«КЛАССИФИКАТОР ИЗОБРАЖЕНИЙ ОВОЩЕЙ»

Выполнил студент

Павлов Сергей Владимирович

Научный руководитель:

Блуменау Марк

Москва, 2023 г.

Оглавление.

| | |
|---|----|
| Глава 1. Постановка и описание задачи. Ожидаемые результаты. | 3 |
| 1.1. Постановка задачи. | 3 |
| 1.2. Ожидаемые результаты. | 4 |
| Глава 2. Краткий обзор существующих решений задачи классификации. | 6 |
| 2.1. Пример 1. InceptionV3 transfer learning. | 6 |
| 2.2. Пример 2. EfficientNet-b0 transfer learning. | 7 |
| 2.3. Пример 3. CNN. | 8 |
| Глава 3. Разведочный анализ данных. | 9 |
| 3.1. Примеры классов. | 9 |
| 3.2. Обзор данных. | 10 |
| Глава 4. Описание baseline модели. | 11 |
| 4.1. Архитектура модели. | 11 |
| 4.2. Результаты обучения модели. | 11 |
| Глава 5. Описание архитектуры проекта. | 12 |
| 5.1. Подготовка данных. | 12 |
| 5.2. Обучение модели. | 12 |
| 5.3. Сохранение обученной модели. | 12 |
| 5.4. Развертывание модели. | 12 |
| 5.5. Мониторинг модели. | 13 |
| Глава 6. Описание плана экспериментов. | 14 |
| 6.1. Расширение исходного набора данных. | 14 |
| 6.2. Оптимизация преобразований исходного набора данных. | 14 |

Глава 1. Постановка и описание задачи. Ожидаемые результаты.

1.1. Постановка задачи.

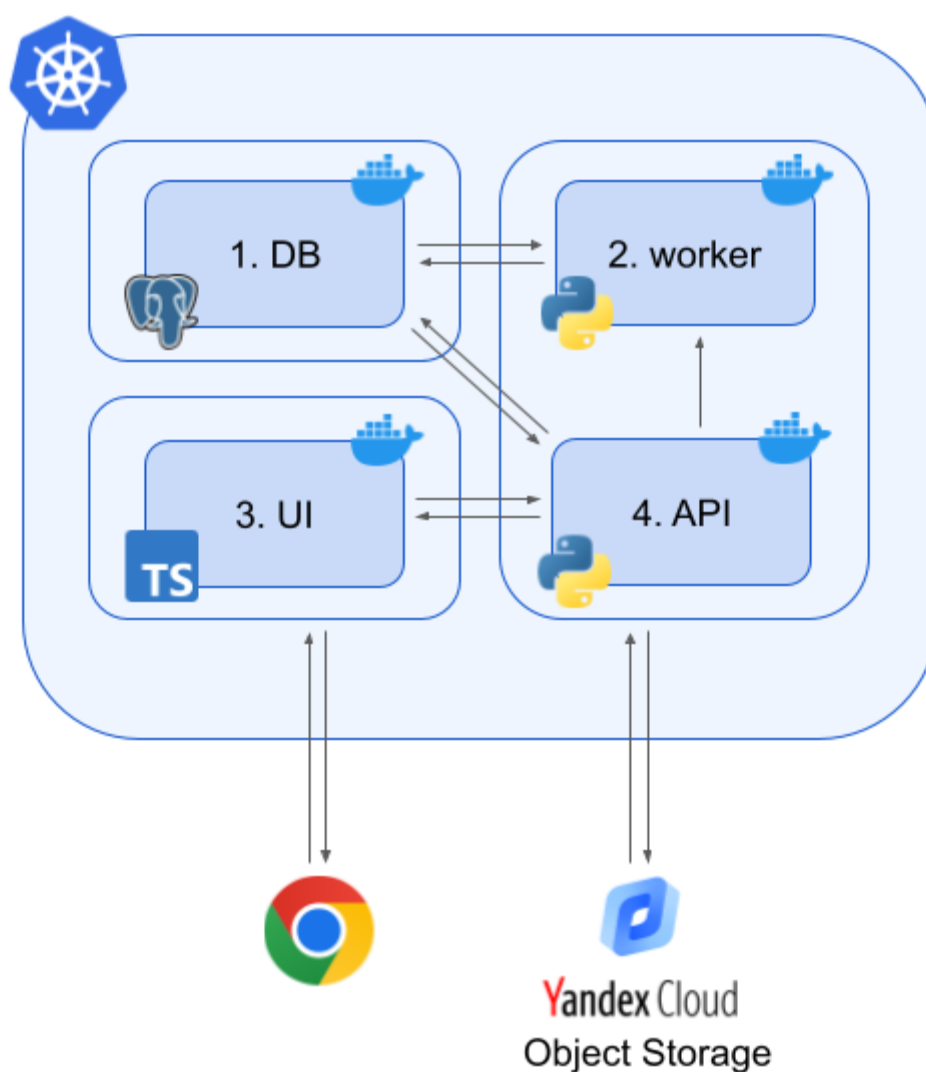
В рамках данной работы планируется использовать [открытый набор данных с фотографиями овощей](#) и выполнить следующие подзадачи:

1. Решить задачу классификации овощей по виду овоща (огурец, помидор и т.д.):
 - 1.1. Для выбора архитектуры воспользоваться примерами успешных решений участников сообщества Kaggle.
 - 1.2. Адаптировать имплементацию архитектуры выбранной модели под стек, используемый в данной работе (Python, PyTorch), обучить модель, оценить качество.
 - 1.3. Подготовить сериализованный объект с моделью для инференса.
2. Найти или разработать алгоритм, позволяющий определить доминантный «цвет» изображения (красный, зелёный и т.д.) и разметить при помощи него исходный набор данных. Также включить в процесс инференса разметку новых изображений с использованием этого алгоритма.
3. Разработать API-сервис, позволяющий:
 - 3.1. Отправлять запрос с комбинацией параметров «количество + вид + цвет» и получать вывод изображений овощей, соответствующих предоставленной комбинации параметров (или визуализацию отсутствия подходящих изображений в базе).
 - 3.2. Загружать пользовательское изображение овоща и получать вывод его классификации по виду и цвету, предсказанной обученными моделями.
4. Разработать web-интерфейс сервиса для взаимодействия с API через браузер.
5. Выполнить развертывание разработанной связки API + UI на демонстрационном стенде с публичным сетевым адресом и провести живую презентацию работы сервиса.

1.2. Ожидаемые результаты.

В качестве результата классификации по виду овоща ожидается PyTorch модель с качеством по accuracy score не менее 0.97 на данных для валидации. Данная задача уже хорошо отработана коллегами из сообщества Kaggle, поэтому целесообразно воспользоваться лучшими архитектурами решений для получения хорошего качества.

В качестве результата разработки веб-сервиса ожидается приложение со следующей архитектурой:



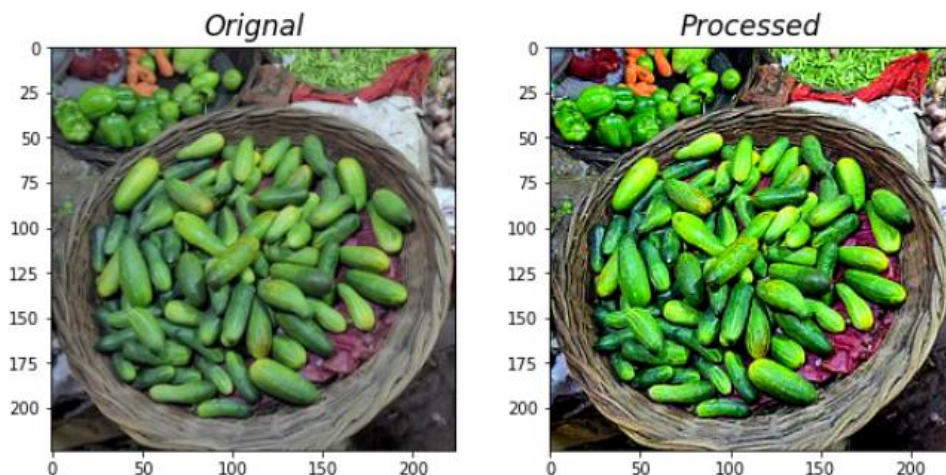
1. На схеме: «DB». База данных PostgreSQL для хранения метаданных об изображениях из набора данных (имя / путь файла и классификация изображения).
2. На схеме: «worker». Вспомогательный Python-сервис для выполнения задач в фоновом режиме на базе Celery или аналогичного инструмента. В частности, для получения предсказаний от обученных моделей без задержки ответа основного API.
3. На схеме: «UI». Веб-сервер упакованных статических файлов для отрисовки пользовательского интерфейса в браузере. Исполнение кодовой базы UI на TypeScript с использованием одного из актуальных SPA-фреймворков.
4. На схеме: «API». API-сервер на базе одного из актуальных веб-фреймворков на Python, обеспечивающий ядро основного функционала.
5. Сборка образов при помощи GitHub CI/CD с последующим хранением артефактов в GitHub Container Registry (ghcr.io).
6. Развертывание в кластере Kubernetes с возможностью доступа к приложению через публичный сетевой адрес.

Глава 2. Краткий обзор существующих решений задачи классификации.

2.1. Пример 1. InceptionV3 transfer learning.

Решение с использованием модели InceptionV3, предобученной на ImageNet. В качестве предобработки исходного набора изображений автор применил следующие преобразования:

- повышение насыщенности цвета
- повышение контрастности
- повышение резкости



Поверх выходного слоя InceptionV3 были добавлены следующие слои:

- слой 2D average pooling
- полносвязный слой с функцией активации ReLU
- слой Dropout с коэффициентом 0.2
- выходной полносвязный слой для классификации с Softmax

Обучение производилось в 5 эпох. В качестве функции потерь была использована категориальная кросс-энтропия. В качестве оптимизационного алгоритма - Adam.

Полученная модель на наборе данных для валидации показала средний accuracy score в размере 0.992. Худшее значение среди всех классов - 0.97. Лучшее значение среди всех классов - 1.00.

2.2. Пример 2. EfficientNet-b0 transfer learning.

[Решение](#) с использованием модели EfficientNet-b0, предобученной на ImageNet. В качестве случайных аугментаций для исходного набора данных были использованы следующие преобразования:

- горизонтальное отражение изображения
- изменение высоты изображения с коэффициентом 0.2
- изменение ширины изображения с коэффициентом 0.2
- поворот изображения с коэффициентом 0.2 и заполнением пустоты ближайшим пикселем
- приближение / отдаление изображения с коэффициентом 0.2

Поверх выходного слоя EfficientNet-b0 были добавлены следующие слои:

- слой 2D average pooling
- выходной полносвязный слой для классификации с Softmax

В качестве функции потерь была использована категориальная кросс-энтропия. В качестве оптимизационного алгоритма - Adam.

Обучение производилось в 2 этапа по 5 эпох.

Сначала были использованы 20% от исходного набора данных для обучения. После этого шага модель на наборе данных для валидации показала средний accuracy score в размере 0.992.

На втором этапе веса из предыдущего обучения использовались в качестве начальных весов модели, а набор данных для обучения был уже полным (100% от исходного набора данных для обучения). Архитектура самой модели относительно предыдущего этапа осталась без изменений. Результатом второго этапа обучения стал средний accuracy score в размере 0.998 на наборе данных для валидации.

2.3. Пример 3. CNN.

[Решение](#) с использованием стандартного подхода - построения пользовательской архитектуры сверточной нейронной сети.

Преобразования исходного набора данных и случайные аугментации не использовались. Выбранная архитектура слоев нейронной сети выглядела следующим образом:

| Тип слоя | Размерность выхода | Кол-во параметров |
|----------------|----------------------|-------------------|
| Conv2D | (None, 150, 150, 32) | 896 |
| MaxPooling2D | (None, 75, 75, 32) | 0 |
| Conv2D | (None, 75, 75, 64) | 18496 |
| MaxPooling2D | (None, 37, 37, 64) | 0 |
| Flatten | (None, 87616) | 0 |
| Dense / Linear | (None, 128) | 11214976 |
| Dropout | (None, 128) | 0 |
| Dense / Linear | (None, 128) | 16512 |
| Dense / Linear | (None, 15) | 1935 |

Обучение производилось в 100 эпох с условием остановки при отсутствии улучшения качества модели на протяжении 5 эпох. В качестве функции потерь была использована категориальная кросс-энтропия. В качестве оптимизационного алгоритма - Adam.

Обучение длилось 15 эпох. Полученная модель на наборе данных для тестирования показала средний accuracy score в размере 0.955.

Глава 3. Разведочный анализ данных.

3.1. Примеры классов.

Примеры изображений каждого класса из набора данных для обучения:

Bean




Bitter_Gourd



Bottle_Gourd



Brinjal



Broccoli



Cabbage



Capsicum



Carrot



Cauliflower



Cucumber



Papaya



Potato



Pumpkin



Radish



Tomato



3.2. Обзор данных.

Исходный набор данных состоит из изображений 21000 изображений 15 видов овощей. Классы сбалансированы ровно, то есть на каждый вид овоща приходится всего 1400 изображений. Исходный набор данных изначально разделен на группы для обучения, тестирования и валидации (train, test, validation) в отношении 70% / 15% / 15%. Это 15000 / 3000 / 3000 изображений соответственно (1000 / 200 / 200 на каждый класс).

Ручной просмотр изображений не позволил выявить откровенные выбросы, требующие исключения из обучения. Но точно имеют место угловые кейсы, когда несколько разных видов овощей попадают вместе на одной фотографии, что может привести к ошибкам классификаторов. Примеры:

true class = Cauliflower true class = Cucumber



true class = Pumpkin



true class = Papaya



Глава 4. Описание baseline модели.

4.1. Архитектура модели.

В качестве основания baseline модели использовалась модель [INCEPTION_V3](#) из хаба pytorch/vision версии 0.10.0, предобученная на наборе данных ImageNet. В качестве весов использовался объект torchvision.models.Inception_V3_Weights.DEFAULT.

Последний слой модели (классификатор) был заменён на полносвязный слой с размерностью выхода, соответствующей количеству классов в используемом в данной работе наборе данных – 15.

Для всех изображений из набора данных было применено преобразование увеличения размера картинки до 299x299, поскольку именно такую размерность модель INCEPTION_V3 ожидает на вход.

В качестве функции потерь была использована категориальная кросс-энтропия. В качестве оптимизационного алгоритма - Adam. Также использовался планировщик StepLR с понижением коэффициента скорости обучения на 0.1 каждые 5 эпох. Размер батча был равен 64.

4.2. Результаты обучения модели.

После обучения в течение 5 эпох модель показала следующие результаты:

| Номер эпохи | Accuracy score на тестовых данных | Accuracy score на валидационных данных |
|-------------|-----------------------------------|--|
| 1 | 89.13% | 98.60% |
| 2 | 97.38% | 99.07% |
| 3 | 98.29% | 99.30% |
| 4 | 98.61% | 99.50% |
| 5 | 98.94% | 99.60% |

Глава 5. Описание архитектуры проекта.

5.1. Подготовка данных.

Исходный набор данных скачан с публичного сегмента Kaggle и размещён в приватном хранилище [Object Storage на базе сервиса «Яндекс.Облако»](#). Данный тип хранилища имеет интерфейс, совместимый с AWS S3, поэтому для доступа к изображениям из среды приложения используется Python-библиотека boto3.

В рамках приложения [реализован](#) API для чтения и записи изображений.

5.2. Обучение модели.

Модель строится на базе Python-библиотеки PyTorch. Обучение модели производится в бесплатной среде Kaggle с использованием GPU. Логика обучения описывается в формате Jupyter Notebook и [сохраняется](#) в контроле версий проекта.

5.3. Сохранение обученной модели.

После обучения модели в целях дальнейшего использования для инференса её объект сериализуется в формат, совместимый с ONNX Runtime, с помощью метода torch.onnx.export. Сериализованный экземпляр модели хранится в том же Object Storage, что используется и для изображений.

5.4. Развертывание модели.

Развертывание выполняется при помощи применения конфигураций сущностей Kubernetes в кластере на личной машине автора проекта. Каждый компонент приложений представляет собой отдельную сущность Kubernetes Deployment:

1. Веб-сервер. Для пользователя точкой входа для взаимодействия с приложением является веб-интерфейс, доступный на одном из поддоменов личного сайта автора. Запросы статических файлов браузером для рендера веб-интерфейса обслуживаются веб-сервером nginx.
2. Сервер API. Действия, выполняемые пользователем в веб-интерфейсе, отправляют запросы из браузера пользователя к серверу API приложения. Логика сервера API выполнена на языке Python с использованием веб-

фрэймворка Starlite. Рантайм сервера API обеспечивается процессами WSGI HTTP сервера Gunicorn с использованием типа воркеров UvicornWorker, поскольку серверное приложение реализовано под интерфейс ASGI.

3. База данных. В качестве базы данных приложения используется СУБД PostgreSQL с хранением данных в Persistent Volume на машине автора.
4. Процессы для исполнения фоновых задач. В рамках рантайма API сервера предусмотрена отправка сигналов на исполнение двух типов фоновых задач:

- 1) отправка загруженного пользователем изображения в S3 Object Storage
- 2) разметка цвета загруженного изображения при помощи алгоритма и предсказание обученной моделью вида овоща на загруженном изображении, а также запись результатов этих действий в базу данных

Исполнение фоновых задач осуществляется процессами, вызываемыми с помощью Python-библиотеки Dramatiq. Для инференса внутри процессов используется ONNX Runtime. Сам файл с моделью либо помещается в Persistent Volume в процессе инициализации сервера API, либо загружается из S3 Object Storage по сети для каждого запуска инференса.

5. Брокер сообщений. Для обмена сообщениями между сервером API и процессами фоновых задач используется менеджер очередей RabbitMQ.

5.5. Мониторинг модели.

Мониторинг скорости разметки новых изображений осуществляется при помощи логирования этой информации через стандартную библиотеку для логирования в Python с дальнейшей визуализацией собранных логов на дэшбордах Grafana.

Глава 6. Описание плана экспериментов.

6.1. Расширение исходного набора данных.

Попробовать дополнить исходный набор данных при помощи генерации изображений через сторонние сервисы (например, OpenAI).

6.2. Оптимизация преобразований исходного набора данных.

В рамках baseline модели использовалось только одно преобразование – увеличение размера изображений с 224^2 до 299^2 . Даже такой простейший подход показал отличный результат - 99.60% accuracy score на валидационных данных).

Тем не менее, в библиотеке PyTorch имеется объект, доступный по пути `Inception_V3_Weights.IMAGENET1K_V1.transforms`, содержащий набор готовых преобразований для инференса на архитектуре InceptionV3.

Попробовать включить в пайплайн применение этих преобразований и оценить изменения качества предсказаний.